Age estimation

DEBESSEL Eric
OLLIVIER François

Dataset

- APPA-REAL (real and apparent age)
- 38 votes par images en moyenne
- 7,591 images
- Split : 4113 train, 1500 valid and 1978 test images

Dataset

-Répartition des âges non-équilibré

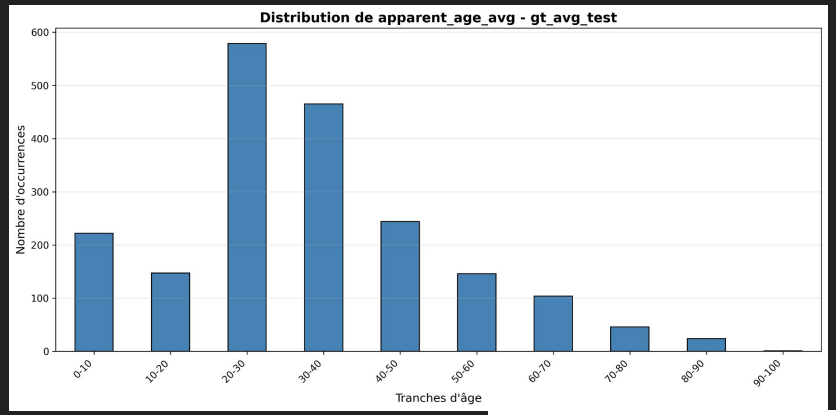

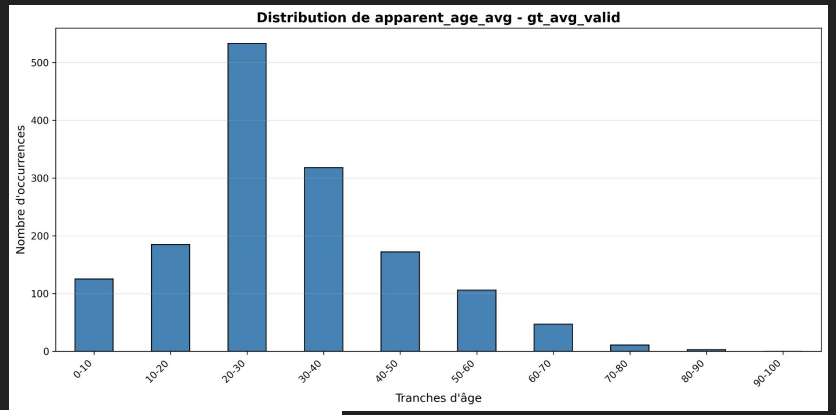

Régression vs Classification

Régression :

- Output : 1 Neurone - > Valeur continue entre 0 et 100

- Loss : L1

Avantage :
- Capture la notion d'ordre des âges

Inconvénients :
- Une seule valeur en sortie (Pas d’incertitudes)
- Des erreurs importantes sur les âges rares

Test MAE : 4.920

Classification :

- Output : 101 Neurone - > softmax -> P(age=k)

- Loss : Cross-Entropy

Avantage :
- La distribution traduit l'incertitude du modèle

Inconvénient :
- Pas de notion de distances entre les classes

Test MAE : 4.860

Label Distribution Learning (LDL)

Classification classique :

- One-hot target : [0, …, 1, … , 0]
- Prédire 20 quand la vérité est 21 a la même pénalité que prédire 99

Label Distribution Learning :

- Gaussian target : $N(y,\sigma^2)$
- Crédit partiel pour les âges proches
- Loss : KL Divergence

Test MAE :
LDL : 4.560

Weighted Sampling

On applique un poids aux classes afin de sélectionner plus souvent les classes peu fréquentes pour l'entraînement

MAE : 4.791
0 - 9 : MAE = 6.567
10 - 19 : MAE = 3.344
20 - 29 : MAE = 3.545
30 - 39 : MAE = 6.075
40 - 49 : MAE = 10.270
50 - 59 : MAE = 5.343
60 - 69 : MAE = 6.213
70 - 79 : MAE = 21.265
80 - 89 : MAE = 11.210

MAE : 4.824
0 - 9 : MAE = 1.767
10 - 19 : MAE = 3.837
20 - 29 : MAE = 3.527
30 - 39 : MAE = 6.028
40 - 49 : MAE = 10.682
50 - 59 : MAE = 4.864
60 - 69 : MAE = 3.774
70 - 79 : MAE = 10.743
80 - 89 : MAE = 8.297

Test-Time Augmentation

Génération des 30 versions :

- Scaling: x1.0, x1.04, x1.10 (zoom de l’image)
- Cropping : 5 Découpage (Centre, 4 Coins)
- Flip : Chaque image elle est retourné horizontalement

3 scaling x 5 cropping x 2 flips = 30 images

Test-Time Augmentation (Mean)

- Chaque version augmentée passe par le modèle
- On prend les 30 vecteurs de logits et on les moyenne élément par élément pour obtenir un seul vecteur de 101 logits."
- On utilise ensuite softmax, puis on calcule l'espérance pour obtenir l'âge prédi

Test-Time Augmentation (Mean)

- Corruption : L’erreur d’une image est supérieure avec l’utilisation du TTA
- Correction : L’erreur est inférieur

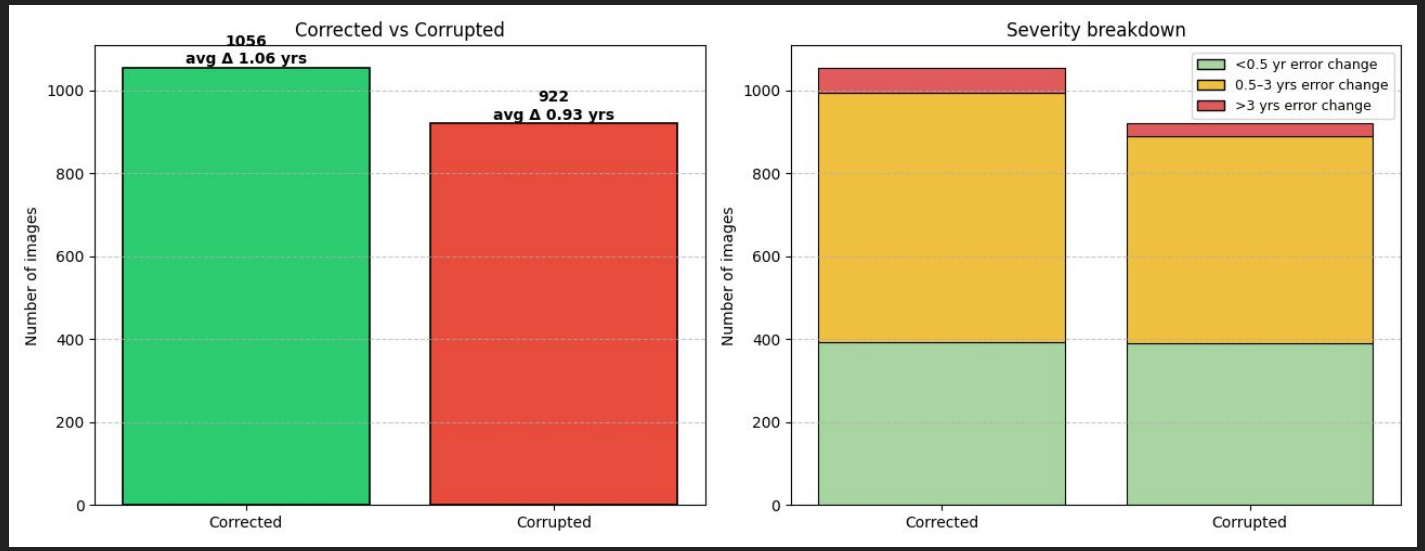

Graphe de comparaison de correction vs corruption en utilisant LDL

TTA (Apprentissage des poids)

Idée :

Toute les augmentations n’ont pas le même poids, un center crop aura probablement plus d’impact qu’un corner crop inversé.

TTA (Apprentissage des poids)

Processus d'apprentissage :

- Pré-calculer les 30 × 101 logits par image sur le jeu de validation
- Apprendre 30 poids (un par augmentation) via SGD pendant 30 epochs
- Loss : Cross-Entropy entre les logits pondérés et le vrai âge
- Contrainte : poids ≥ 0 après chaque step

TTA (Apprentissage des poids)

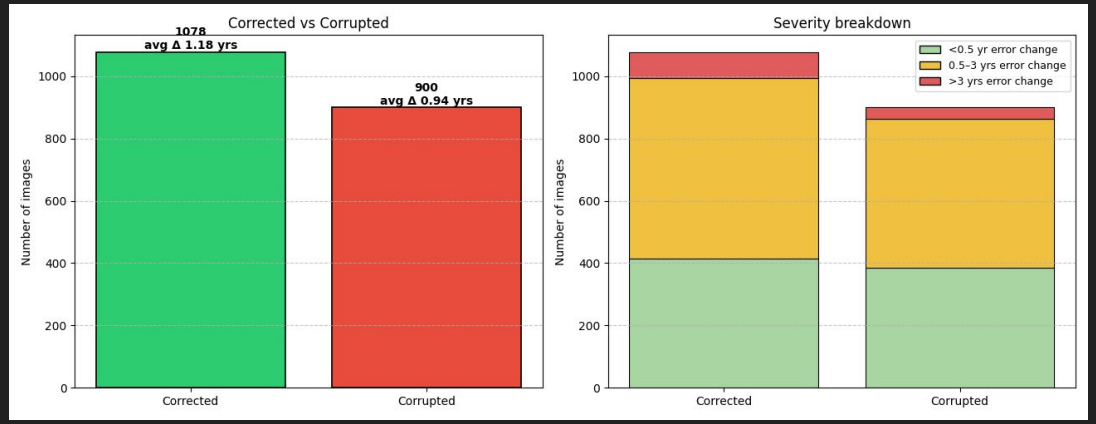

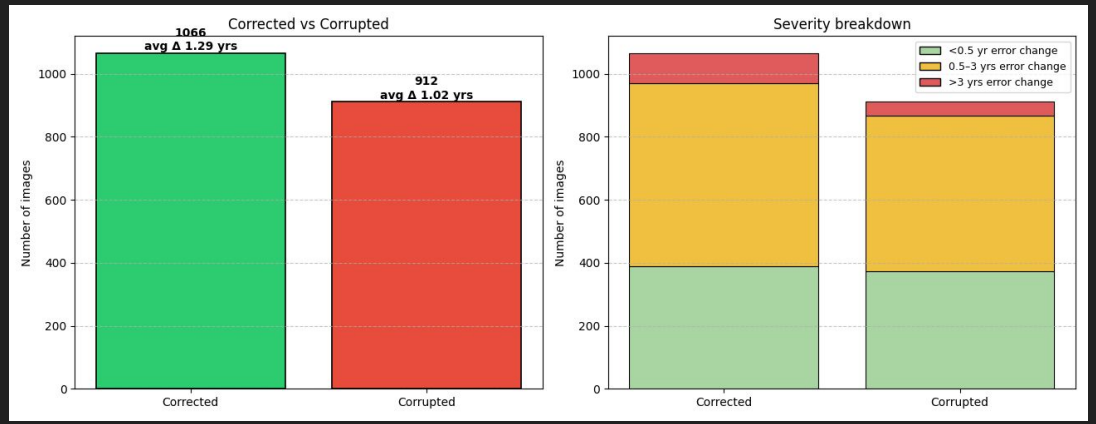

- En haut le graphe de correction et corruption de classification avec TTA Mean, en bas avec TTA Weighted

- Pour la classification, le TTA weighted augmente l'amplitude des changements dans les deux sens par rapport au TTA mean Mais l'écart entre correction et corruption se maintient (~0.27), ce qui préserve un gain net en MAE

Tableau de comparaison

Modèle	MAE Test	MAE + TTA Mean	MAE + TTA Weighted
Régression	4.920	4.758	4.757
Classification	4.860	4.646	4.635
LDL	4.560	4.435	4.440

Résultat final : 4.860 (Baseline) -> 4.435 (+0.425)

Conclusion

- LDL > Classification > Régression
- TTA améliore tous les modèles au coût d’un plus long temps d'exécution
- TTA weighted : le gain est marginal, utile quand le modèle est faible, négligeable quand le modèle est déjà fort.

Références

- “Better Aggregation in Test-Time Augmentation”, 2021
  Divya Shanmugam, Davis Blalock, Guha Balakrishnan, John Guttag :
  https://arxiv.org/abs/2011.11156

- “Label Distribution Learning”, 2016
  Xin Geng :
  https://arxiv.org/abs/1408.6027